





LARGE LANGUAGE MODELS

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026



OBJECTIFS

01


Savoir définir le traitement du langage naturel. Connaître l'historique et les représentation vectorielles.



02

Maîtriser le mécanisme d'attention et l'architecture des Transformers avec les modèles de type Bert et GPT.


03

Comprendre le pré-entraînement, la spécialisation des modèles et les différentes techniques de prompting.





PROGRAMME



1.

Introduction au NLP

2.

Evolution des modèles

3.

Architecture des
Transformers

4.

Bert

5.

GPT

6.

Fine-tuning et prompting



Partie 4 :

BERT

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026

BERT


BERT, qui signifie Bidirectional Encoder Representations from Transformers, est un modèle de traitement du langage naturel développé par Google AI en 2018.

Il a marqué une révolution dans le domaine du NLP grâce à sa capacité à comprendre le contexte des mots dans une phrase en analysant les deux directions (gauche à droite et droite à gauche) simultanément.

BERT est basé sur l'architecture Transformer. Il utilise uniquement l'encodeur pour comprendre le texte. Contrairement à des modèles comme GPT, qui lisent les phrases de manière unidirectionnelle,

BERT utilise une attention bidirectionnelle pour comprendre le contexte global.

BERT




Masked Language Modeling :


Un pourcentage de mots d'une phrase est masqué (remplacé par un token spécial [MASK]). Le modèle doit prédire les mots manquants.

BERT


Transformer



GPT*



BERT*



*Illustrative example, exact model architecture may vary slightly

BERT

Paramètres principaux :

Nombre de couches (ou blocs) : 12 (BERT-Base) ou 24 (BERT-Large).

Dimensions des embeddings : 768 (BERT-Base) ou 1024 (BERT-Large).

Nombre de têtes d'attention : 12 (BERT-Base) ou 16 (BERT-Large).

Taille totale des paramètres : 110M de paramètres (BERT-Base) ou 340M de paramètres (BERT-Large).

BERT

Bidirectional Encoder Representations from Transformers (2018)

Modèle basé sur l'architecture Transformers entraîné par Google.

- Vocabulaire de 30 000 tokens
- Modèle de base : 12 couches, dimension de 768, 110M de paramètres
- Modèle large : 12 couches, dimension de 1024, 340M de paramètres
- Entraînement sur 64 TPU pendant 4 jours complets.

Task	Average	Grammatical	Sentiment Analysis	Similarity	Paraphrase	Question Similarity	Contradiction	Answerable	Entail
BERT _{LARGE}	82.1	60.5	94.9	86.5	89.3	72.1	86.7/85.9	92.7	70.1
BERT _{BASE}	79.6	52.1	93.5	85.8	88.9	71.2	84.6/83.4	90.5	66.4
OpenAI GPT	75.1	45.4	91.3	80.0	82.3	70.3	82.1/81.4	87.4	56.0
Pre-OpenAI SOTA	74.0	35.0	93.2	81.0	86.0	66.1	80.6/80.1	82.3	61.7
BiLSTM+ELM o+Attn	71.0	36.0	90.4	73.3	84.9	64.8	76.4/76.1	79.8	56.8

BERT

Bidirectional Encoder Representations from Transformers (2018)


Pré-entraînement : Création d'un modèle ayant des connaissances générales sur le langage grâce à des tâches auto-supervisées. Cette technique permet de mutualiser la partie la plus conséquente de l'entraînement et donc de largement réduire le temps et les coûts pour des tâches spécifiques.

- Mask ML sur ~15% des tokens
- Next Sentence Prediction (50 true/50 false)
- Utilisation de BooksCorpus (800M de mots) et de la version anglaise de Wikipedia (2500M de mots).

BERT

Bidirectional Encoder Representations from Transformers (2018)

Fine tuning : Spécialisation du modèle pour une tâche donnée. Le format des entrées/sorties est adapté, la couche de sortie est complètement modifiée et le reste du modèle se met à jour lors de l'apprentissage.




BERT

Bidirectional Encoder Representations from Transformers (2018)

Utilisation de Bert comme outil de vectorisation.

Les vecteurs fournis par Bert sont l'entrée d'un autre modèle d'apprentissage, réalisant la tâche finale souhaitée.



BERT

La sortie de l'encodeur BERT est une séquence de vecteurs contextuels correspondant à chaque entrée. Les sorties comprennent des tokens spéciaux comme :

- le token [CLS] qui est le premier vecteur et représente le résumé global de la séquence. Il est utilisé pour les tâches comme la classification.
- le token [SEP] sert de délimiteur pour différencier deux phrases dans une tâche.

Les autres tokens représentent les vecteurs contextuels de chaque mot.

Input	[CLS]	my	dog	is	cute	[SEP]	he	likes	play	##ing	[SEP]
Token Embeddings	$E_{[CLS]}$	E_{my}	E_{dog}	E_{is}	E_{cute}	$E_{[SEP]}$	E_{he}	E_{likes}	E_{play}	$E_{\# \# ing}$	$E_{[SEP]}$
	+	+	+	+	+	+	+	+	+	+	+
Segment Embeddings	E_A	E_A	E_A	E_A	E_A	E_A	E_B	E_B	E_B	E_B	E_B
	+	+	+	+	+	+	+	+	+	+	+
Position Embeddings	E_0	E_1	E_2	E_3	E_4	E_5	E_6	E_7	E_8	E_9	E_{10}

CAMEMBERT

Adaptation française de RoBERTa

Utilisation de l'architecture RoBERTa avec entraînement sur un corpus en français.

RoBERTa : Masking dynamique, pas d'entraînement sur la tâche de NSP, plus grands batchs, entraînement sur plus de données pendant plus longtemps.

Corpus : partie française d'OSCAR (extrait filtré de Common Crawl) → 138GB au total

Modèle de base : 12 couches, dimension de 768, 110M de paramètres

Modèle large : 12 couches, dimension de 1024, 340M de paramètres