





LARGE LANGUAGE MODELS

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026



OBJECTIFS

01


Savoir définir le traitement du langage naturel. Connaître l'historique et les représentation vectorielles.



02

Maîtriser le mécanisme d'attention et l'architecture des Transformers avec les modèles de type Bert et GPT.


03

Comprendre le pré-entraînement, la spécialisation des modèles et les différentes techniques de prompting.





PROGRAMME



1.

Introduction au NLP

2.

Evolution des modèles

3.

Architecture des
Transformers

4.

Bert

5.

GPT

6.

Fine-tuning et prompting



Partie 5 :

GPT

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026

GPT

GPT, qui signifie Generative Pre-trained Transformers, est un modèle de traitement du langage naturel développé par Open AI en 2018. Il a marqué une révolution dans le domaine du NLP grâce à sa capacité à générer du texte de façon cohérente pour un contexte donné.


GPT est basé sur l'architecture Transformer. Il utilise uniquement le décodeur pour générer du texte. Contrairement à des modèles comme Bert, qui lisent les phrases de manière bidirectionnelle, GPT

utilise une attention unidirectionnelle pour prédire la suite d'une séquence donnée.

Paramètres principaux :

- Nombre de couches (ou blocs) : 12.
- Dimensions des embeddings : 768.
- Nombre de têtes d'attention : 12.
- Taille totale des paramètres : 110M de paramètres.

GPT




Causal Language Modeling :


Le modèle voit une séquence de mots et doit prédire le mot suivant.

GPT


Transformer



GPT*



BERT*




*Illustrative example, exact model architecture may vary slightly

GPT

Generative Pretrained Transformer (2018)

Les modèles de génération de texte s'entraînent sur une tâche différente. La tâche consiste à prédire le mot suivant dans une phrase après avoir lu les n mots précédents. On parle alors de modélisation linguistique causale, car le résultat dépend des entrées passées et présentes, mais pas des entrées futures.




GPT

Generative Pretrained Transformer (2018)

En entrée, les mots sont représentés en tant que vecteurs denses à l'aide d'embeddings appris (WordPiece ou Byte-Pair Encoding). Ces vecteurs sont enrichis d'encodages positionnels pour capturer l'ordre des mots dans la séquence.

En sortie, les prédictions du modèle sont faites via un softmax sur un vocabulaire, avec des poids partagés entre les embeddings d'entrée et de sortie.




GPT

Generative Pretrained Transformer (2018)

GPT est pré-entraîné sur la tâche principale de prédiction du prochain token pour une séquence donnée.

Cela permet d'utiliser un apprentissage auto-supervisé sur un nombre très important de données.



GPT

Generative Pretrained Transformer (2018)

La particularité de GPT est que les datasets utilisés pour entraîner les modèles n'ont pas été rendu public.

~ 40Go de données pour GPT-2 et 570Go pour GPT-3.

~ Temps d'entraînement de l'ordre de la semaine pour GPT-2 et de l'ordre du mois pour GPT-3.

