





LARGE LANGUAGE MODELS

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026



OBJECTIFS

01


Savoir définir le traitement du langage naturel. Connaître l'historique et les représentations vectorielles.



02

Maîtriser le mécanisme d'attention et l'architecture des Transformers avec les modèles de type Bert et GPT.


03

Comprendre le pré-entraînement, la spécialisation des modèles et les différentes techniques de prompting.





PROGRAMME



1.

Introduction au NLP

2.

Evolution des modèles

3.

Architecture des
Transformers

4.

Bert

5.

GPT

6.

Fine-tuning et prompting



Partie 6 :

FINE-TUNING ET PROMPTING

Marion Schaeffer
marion.schaeffer@ext.nexa.fr

Mai 2026


LLM

Large Language Model ou **Grands Modèles de Langage**

- Réseaux de neurones avec énormément de paramètres (de l'ordre du milliard)
- Entraînement sur de grandes quantités de données grâce à des techniques auto ou semi supervisées
- Modèles à usage généraliste
- En NLP, les modèles acquièrent des connaissances sur la syntaxe, la sémantique ainsi que des connaissances globales sur le monde via les exemples utilisés pendant l'entraînement
- Tâche de prédiction de mots, possibilités d'hallucinations.

LLM

LLM et nombre de paramètres



LLM

Spaces

open-llm-leaderboard/open_llm_leaderboard

like 11.9k

Running on CPU UPGRADE

App

Files

Community 1024

🤖 Open LLM Leaderboard

The previous Leaderboard version is live [here](#) 📄 Feeling lost? Check out our [documentation](#) 📄

You'll notably find explanations on the evaluations we are using, reproducibility guidelines, best practices on how to submit a model, and our FAQ.

🏆 LLM Benchmark

🚀 Submit

UPI Model Vote

Search

Separate multiple queries with ','.

Select Columns to Display:

☒ Average 📈

☒ IFEval

☐ IFEval Raw

☒ BBH

☐ BBH Raw

☒ MATH Lvl 5

☐ MATH Lvl 5 Raw

☒ GPQA

☐ GPQA Raw

☒ MUSR

☐ MUSR Raw

☒ MMLU-PRO

☐ MMLU-PRO Raw

☐ Type

☐ Architecture

☐ Precision

☐ Not_Merged

☐ Hub License

☐ #Params (B)

☐ Hub ❤️

☐ Model sha

☐ Submission Date

☐ Upload To Hub Date

☐ Chat Template

☐ Generation

☐ Base Model

☒ CO₂ cost (kg)

Model types

☒ 🗨 chat models (RLHF, DPO, IFT, ...)

☒ 🔷 fine-tuned on domain-specific datasets

☒ 🟡 base merges and moerges

☒ 🟢 pretrained

☒ 🌸 multimodal

☒ 🟩 continuously pretrained

Precision

☒ bfloat16

☒ float16

☒ 4bit

Select the number of parameters (B)

7

10

Hide models

☒ Deleted/incomplete

☒ Merge/MoErge

☐ MoE

☒ Flagged

☐ Show only maintainer's highlight

LLM

Arena (battle) Arena (side-by-side) Direct Chat Leaderboard About Us

Chatbot Arena LLM Leaderboard: Community-driven Evaluation for Best LLM and AI chatbots

Twitter | Discord | Blog | GitHub | Paper | Dataset | Kaggle Competition

Chatbot Arena ([lmarena.ai](#)) is an open-source platform for evaluating AI through human preference, developed by researchers at UC Berkeley [SkyLab](#) and [LMSYS](#). With over 1,000,000 user votes, the platform ranks best LLM and AI chatbots using the Bradley-Terry model to generate live leaderboards. For technical details, check out our [paper](#).

Chatbot Arena thrives on community engagement — cast your vote to help improve AI evaluation!

New Launch! Copilot Arena: [VS Code Extension](#) to compare Top LLMs

Arena NEW: Overview Arena (Vision) Arena-Hard-Auto Full Leaderboard

Total #models: 169. Total #votes: 2,296,813. Last updated: 2024-11-21.

Code to recreate leaderboard tables and plots in this [notebook](#). You can contribute your vote at [lmarena.ai](#)!

Category

Overall

Apply filter

☐ Style Control

☐ Show Deprecated

Overall Questions

#models: 169 (100%) #votes: 2,296,813 (100%)

Rank* (UB)	Rank (StyleCtrl)	Model	Arena Score	95% CI	Votes	Organization	License
1	2	Gemini-Exp-1121	1365	+8/-6	5625	Google	Proprietary
1	1	ChatGPT-4o-latest (2024-11-20)	1361	+4/-5	10658	OpenAI	Proprietary
3	5	Gemini-Exp-1114	1344	+4/-5	12778	Google	Proprietary
4	2	o1-preview	1334	+4/-4	27835	OpenAI	Proprietary
5	7	o1-mini	1308	+3/-4	31992	OpenAI	Proprietary
5	5	Gemini-1.5-Pro-002	1301	+5/-3	27336	Google	Proprietary
7	10	Grok-2-08-13	1289	+4/-3	52102	xAI	Proprietary


SPÉCIALISATION

La spécialisation d'un modèle pré-entraîné désigne le processus d'adaptation d'un modèle pré-entraîné à un usage global pour une tâche, un domaine ou un ensemble de données spécifiques. Cela s'effectue généralement par le biais d'un entraînement supplémentaire sur des données spécifiques au domaine, tout en conservant les connaissances acquises par le modèle pré-entraîné.

- fine-tuning : ajustement des paramètres du modèle à l'aide d'un ensemble de données plus petit et spécialisé afin d'améliorer les performances sur une tâche particulière.
- domain adaptation : spécialisation du modèle pour un secteur ou un domaine spécifique (par exemple, imagerie médicale, traitement de textes juridiques).
- transfer learning : exploitation des connaissances issues d'un vaste ensemble de données générales afin d'améliorer les performances sur un problème connexe mais plus spécifique.


TRANSFER LEARNING

Le transfer learning (ou apprentissage par transfert) est une technique en apprentissage automatique où un modèle entraîné sur une tâche (source) est réutilisé comme point de départ ou base pour une autre tâche (cible). Plutôt que d'entraîner un modèle à partir de zéro, on exploite les représentations apprises lors d'un pré-entraînement sur un grand corpus général pour l'adapter à des tâches spécifiques avec des données limitées.



TRANSFER LEARNING


Comme le but est de spécialiser un modèle pré-entraîné sur une nouvelle tâche, les poids initiaux ne sont pas modifiés, une nouvelle couche est ajoutée.



FINE-TUNING

Le fine-tuning (ou affinage) est une technique en apprentissage automatique où un modèle pré-entraîné sur une tâche générale est réentraîné et ajusté sur une tâche spécifique en modifiant ses paramètres. En NLP, le fine-tuning consiste à adapter un modèle de langage général (comme BERT, GPT ou T5) pour résoudre des problèmes précis comme la classification de texte, la traduction, ou la reconnaissance d'entités nommées.

Les poids du modèle sont modifiés.



PROMPTING

Le prompt engineering est une technique qui consiste à concevoir des instructions textuelles (prompts) optimales pour interagir avec des modèles de langage pré-entraînés. Ces prompts orientent le comportement du modèle afin d'obtenir des réponses pertinentes pour une tâche donnée, sans nécessiter de ré-entraînement ou de modification du modèle

Différentes techniques existent.

Comment puis-je vous aider ?

Poser une question

+ Rechercher Raisonner ...

↑

PROMPTING

Le zero-shot :

Le modèle effectue la tâche en se basant uniquement sur le prompt (aucun exemple fourni).

Comment puis-je vous aider ?

Generate a data sample of 10 examples in JSON format with the key "sentence" and a sentence of your choice as the value and the key "number" with a random number between 0 and 5 as the value.



Rechercher



Raisonner



PROMPTING

Le one-shot :

Le prompt inclut un exemple annoté en plus des instructions pour guider la compréhension du modèle

Comment puis-je vous aider ?

Generate a data sample of 10 examples in JSON format with the key "sentence" and a sentence of your choice as the value and the key "number" with a random number between 0 and 5 as the value.

Here is an example for your record:

```
{"sentence": "I enjoy sunny days.", "number": 4}
```

+ Rechercher Raisonner ...



PROMPTING

Le few-shot :

Le prompt inclut quelques exemples annotés en plus des instructions pour guider la compréhension du modèle

Comment puis-je vous aider ?

Generate a data sample of 10 examples in JSON format with the key "sentence" and a sentence of your choice as the value and the key "number" with a random number between 0 and 5 as the value.

Here are examples for your record:

```
{"sentence": "I enjoy sunny days.", "number": 4}
```

```
{"sentence": "The day after Saturday is Sunday.", "number": 2}
```

```
{"sentence": "Dogs are much smarter than cats.", "number": 1}
```



Rechercher



Raisonner

